IA GENERATIVA AL SERVICIO DE LA INVESTIGACIÓN

Kalish Manta Analytics

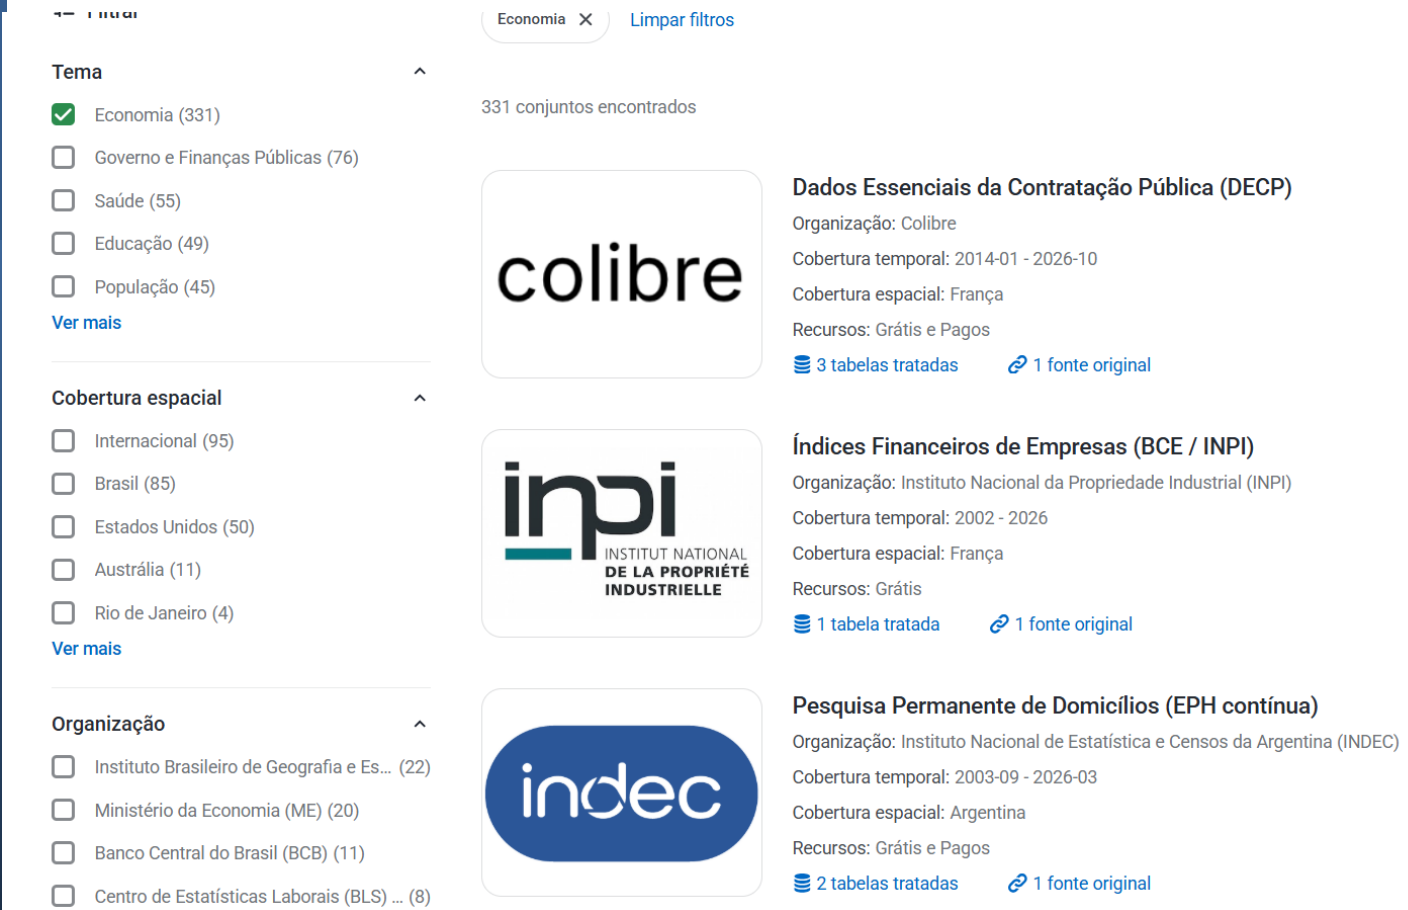
Un Chatbot asistente que conecta a cada investigador con la base de datos económicos del Perú



Presentado por

Roberto

Motivación


Economia
Limpar filtros
Tema
Economia (331)
Governo e Finanças Públicas (76)
Saúde (55)
Educação (49)
População (45)
Ver mais
Cobertura espacial
Internacional (95)
Brasil (85)
Estados Unidos (50)
Austrália (11)
Rio de Janeiro (4)
Ver mais
Organização
Instituto Brasileiro de Geografia e Es... (22)
Ministério da Economia (ME) (20)
Banco Central do Brasil (BCB) (11)
Centro de Estatísticas Laborais (BLS) ... (8)
331 conjuntos encontrados
colibre
Dados Essenciais da Contratação Pública (DECP)
Organização: Colibre
Cobertura temporal: 2014-01 - 2026-10
Cobertura espacial: França
Recursos: Grátis e Pagos
3 tabelas tratadas
1 fonte original
inpi
INSTITUT NATIONAL DE LA PROPRIÉTÉ INDUSTRIELLE
Índices Financeiros de Empresas (BCE / INPI)
Organização: Instituto Nacional da Propriedade Industrial (INPI)
Cobertura temporal: 2002 - 2026
Cobertura espacial: França
Recursos: Grátis
1 tabela tratada
1 fonte original
indec
Pesquisa Permanente de Domicílios (EPH contínua)
Organização: Instituto Nacional de Estatística e Censos da Argentina (INDEC)
Cobertura temporal: 2003-09 - 2026-03
Cobertura espacial: Argentina
Recursos: Grátis e Pagos
2 tabelas tratadas
1 fonte original

01

Propósito y problema

Por qué existe el asistente y a quién ayuda

02

Fuente de datos

Bases públicas procesadas y su ficha en PDF

03

Stack tecnológico

LangChain, FAISS, Qwen3 Embedding y Qwen3.5 con QLoRA

04

Arquitectura

Del mensaje del usuario a la respuesta con acceso a los datos

05

Calidad del modelo

Cómo evitamos que memorice y que invente datos

06

Demo y próximos pasos

La web, el repositorio y la hoja de ruta

Un asistente entrenado para guiar la búsqueda de datos

El chatbot conoce en detalle cada base de datos del catálogo **y la explica en el lenguaje del investigador:**

FOCO PRINCIPAL

Estudiantes de pregrado, posgrado, y consultore.



Estudiantes

Tesis, trabajos de curso y primeras investigaciones. Reciben orientación paso a paso y la base adecuada para su pregunta.



Investigadores junior y senior

Respuestas directas con variables, periodos, llaves de unión y advertencias técnicas de cada base.



Profesionales y consultores

Informes, evaluaciones de políticas y análisis para el sector público y privado.

El problema: investigar empieza por encontrar datos



Fuentes dispersas

Cada dato vive en una institución distinta: INEI, ministerios, observatorios, catálogos satelitales.



Poca documentación

Variables sin descripción, cambios de codificación y advertencias que solo se descubren al analizar.



Procesamiento costoso

Descargar, limpiar, unir y validar consume semanas antes de empezar a investigar.



Barrera para estudiantes

Sin experiencia previa, elegir la base correcta para una pregunta es el primer gran obstáculo.



La solución

Un chat que da acceso a bases de datos procesados y documentadas.

- **Entiende** la pregunta de investigación del usuario.
- **Recomienda** la base adecuada y explica su contenido.
- **Advierte** limitaciones y cómo unirla con otras fuentes.
- **Entrega** el link de acceso a los datos (Dropbox) y su ficha.

Así lo vive el usuario: tres pasos

1

Describe tu investigación

Resume el abstract, la hipótesis o el objetivo del trabajo o análisis económico.

2

Recibe la recomendación

El asistente explica qué base usar, qué contiene, su periodo, variables clave y limitaciones.

3

Accede a los datos

Debajo de la respuesta aparece el link a la carpeta con los datos y la ficha técnica en PDF.

Ejemplo: “Mi tesis evalúa si la pobreza distrital bajó entre 2013 y 2018 en la sierra sur” → el asistente recomienda la Tasa de pobreza monetaria a nivel distrito 2013 y 2018 y entrega link de DropBox.

02

Fuente de datos

Bases públicas procesadas, cada una con una ficha técnica en PDF



Bases públicas, procesadas y listas para investigar

15

bases de datos

en el catálogo actual

8

temas

de economía y ciencias sociales

15

fichas PDF

una por base, con todo detalle

1995–2025

cobertura

según la base

Fuentes oficiales y académicas

- INEI · MINEDU · MININTER · Ministerio Público
- SENAMHI · MTC · RAISG
- Proética / Ipsos · Google Earth Engine

Procesadas y listas para usar

- Paneles construidos y variables documentadas
- Stata, SPSS, Excel, CSV y shapefiles
- Carpeta en Dropbox con datos y ficha en PDF

Catálogo: 15 bases en 8 temas

Educación

Censo Escolar 2006-2023 · SISEVE 2014-2023 (bullying y violencia escolar)

Empresas y productividad

Panel de empresas de la Encuesta Económica Anual (EEA) 2012-2020

Pobreza

Tasa de pobreza monetaria a nivel distrito 2013 y 2018

Seguridad ciudadana

Denuncias SIDPOL hasta marzo de 2025 · RENADESPLE: personas detenidas

Política y corrupción

Encuesta Nacional sobre Corrupción de Proética 2025 (XIII edición)

Teledetección

Luces nocturnas por distrito 1995-2013 · Elevación, precipitación, pendiente y temperatura

Economías ilícitas

Shapefile de minería ilegal en la Amazonía (RAISG)

Cartografía y vías

Unidades administrativas 2007 y 2017 · Límite del Perú · Red vial 2018 · Fenómeno El Niño

La ficha PDF: el corazón del RAG

Estructura de cada ficha

- Nombre de la base de datos
- Resumen
- Ficha rápida: tema, unidad, cobertura, periodo, formato, tamaño y llave para unir
- Palabras clave y sinónimos
- Preguntas que ayuda a responder
- Archivos y variables principales
- Notas y advertencias de uso
- Fuente y link de Dropbox

Texto completo indexado

Se divide en chunks y se vectoriza: es lo que el asistente lee para responder.

Título oficial

La línea “Nombre de base de datos” se usa en el catálogo, en el prompt y en los links.

Link de Dropbox a la metadata

Se extrae del hipervínculo del PDF y se agrega al final de la respuesta: el LLM nunca lo escribe.

Palabras clave y preguntas

Sinónimos y preguntas típicas mejoran la búsqueda semántica.

Panel de empresas de la Encuesta Económica Anual (EEA) 2012-2020: productividad y estados financieros

Nombre de base de datos: Panel de empresas de la Encuesta Económica Anual (EEA) 2012-2020: productividad y estados financieros

Resumen

Panel de datos a nivel empresa construido con la Encuesta Económica Anual (EEA). La misma empresa se observa en todos los años del periodo, lo que permite análisis de datos de panel con efectos fijos.

La información más importante son las medidas de productividad a nivel empresa: productividad laboral y productividad total de factores (PTF/TFP) estimada por los métodos de Olley-Pakes, Levinsohn-Petrin, Wooldridge y efectos fijos, incluso con función de producción translog.

También contiene información financiera (ingresos, producción, valor agregado, gasto en insumos intermedios, gastos financieros, utilidades, impuesto a la renta), del balance general (stock de capital, capital intangible, activos y pasivos de corto y largo plazo) y de empleo (total de trabajadores, por sexo, permanentes y eventuales). El periodo va de 2012 a 2020.

Palabras clave y sinónimos

Encuesta Económica Anual, EEA, INEI, datos de empresas, firm-level data, panel de empresas, productividad, productividad total de factores, PTF, TFP, total factor productivity, Olley-Pakes, Levinsohn-Petrin, Wooldridge, función de producción, translog, Cobb-Douglas, productividad laboral, labor productivity, valor agregado, ventas, ingresos, stock de capital, capital intangible, balance general, pasivos, deuda, financiamiento, gastos financieros, empleo, trabajadores, empleo femenino, CIIU, sector económico, manufactura, comercio.

Preguntas que esta base de datos ayuda a responder

- ¿Hay datos de productividad total de factores (PTF/TFP) de empresas peruanas?
- ¿Cómo estimar productividad con Olley-Pakes o Levinsohn-Petrin para empresas del Perú?
- ¿Qué base tiene el balance general y los estados financieros de empresas en panel?
- ¿Cómo afectó un shock climático (Fenómeno El Niño, inundaciones) a la productividad de las empresas?
- ¿Cuál es la relación entre financiamiento de corto y largo plazo y el crecimiento de las empresas?
- ¿Cuántos trabajadores hombres, mujeres, permanentes o eventuales tienen las empresas por sector?
- Busco un panel de empresas por sector CIIU para analizar inversión, capital intangible o patentes.

Link de Acceso al final de cada documento

Notas y advertencias de uso

- La ubicación de la empresa está a nivel de distrito (centroide), no la dirección exacta.
- El panel incluye solo las 1,633 empresas presentes en los 9 años, por lo que no representa entrada ni salida de empresas.
- Los montos financieros son nominales; usar la variable ipc para expresarlos en términos reales..
- Usar la variable factor para resultados representativos de la encuesta.

Fuente y acceso

Fuente: https://proyectos.inei.gob.pe/microdatos/

Link de Dropbox:
https://www.dropbox.com/scl/fo/ewjehabtbq71p8mfz0mi1/AIMVA55g5c7ybTG6qK0YWcI?rlkey=a2u8y4pwbbpl8zl6mxvy7f9ip&st=l9c3kdby&dl=0

03

Stack tecnológico

Open Models, orquestación con LangChain e implementación en Local



Stack tecnológico de punta a punta

INTERFAZ

Streamlit · FastAPI (opcional)

Chat, sliders de búsqueda, catálogo y link público con Tailscale Funnel

ORQUESTACIÓN

LangChain

Carga de documentos, chunks, vector store y búsqueda con score

VECTOR DATABASE

FAISS

Índice de 75 chunks con metadata: título, tema, posición y link

EMBEDDINGS

Qwen3-Embedding 4B · Ollama

Vectores de 2560 dimensiones, en CPU, con instrucción en la consulta

LLM

Qwen3.5-4B + QLoRA (Unsloth)

Fine-tuned para el rol del asistente y para usar solo las fichas

INFRAESTRUCTURA

GPU RTX 5050 8 GB · CUDA 13

LangChain orquesta el sistema RAG



Lectura

PDFReader con pypdf: texto con tildes y puntuación, título y link de Dropbox

Document

Cada ficha pasa a un Document de LangChain con su metadata

Chunks

Splitter recursivo: 900 caracteres, 100 de solape, 75 chunks

Vector store

FAISS con embeddings de Qwen3, guardado en disco

Búsqueda

Búsqueda con score sobre todos los chunks del índice

Metadata de cada chunk

`source` · `dataset` · `title` · `category` · `dropbox_link` · `chunk_id`

El chunk_id permite agregar la ficha rápida (chunk 0) de cada base recuperada y evitar repetir texto.

Búsqueda por similitud: cómo se elige el contexto

SIMILITUD COSENO

$$\text{similitud} = 1 - d^2 / 2$$

d^2 es la distancia L2 al cuadrado que devuelve FAISS; con vectores de norma 1 equivale al coseno.

Umbral 0.53

Mínimo para usar una ficha

Margen 0.10

Respecto a la mejor base

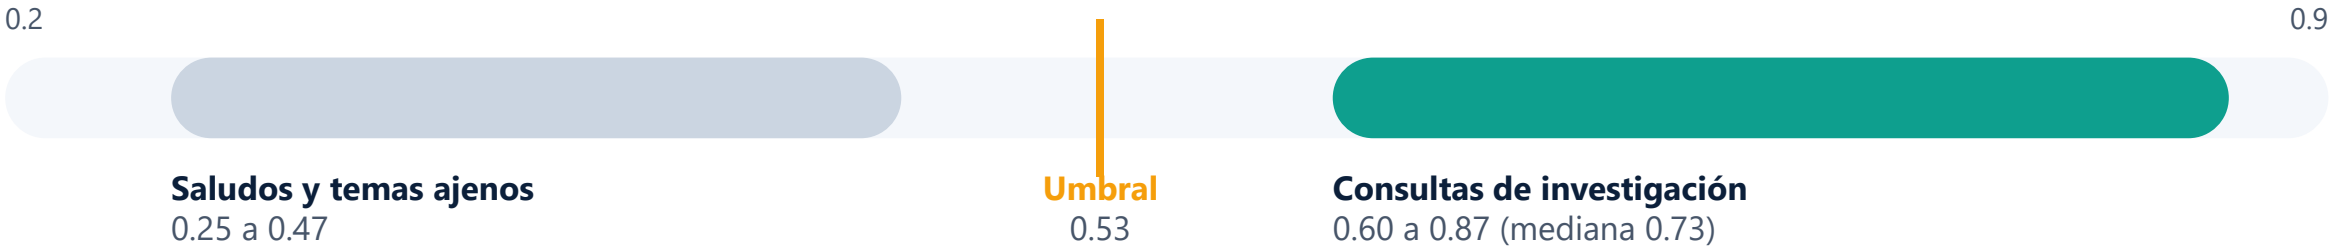
Máx. 3 bases

Distintas, sin repetir texto

Ficha + chunk

Ficha rápida y fragmento más parecido

Scores medidos sobre el índice actual



LLM: Qwen3.5-4B, un modelo híbrido y eficiente

4.54B
parámetros

32
capas: 8 de atención completa y 24 lineales

~3.5 GB
de VRAM en 4 bits NF4

0.2
temperatura: respuestas consistentes

Arquitectura híbrida: una capa de atención completa cada cuatro



- Atención completa (8): q, k, v, o
- Atención lineal (24): in_proj_qkv, in_proj_z, out_proj

Fine-tuning con QLoRA y Unsloth

- **W** pesos del modelo base: congelados en 4 bits NF4
- **A, B** matrices LoRA de rango r = 16: lo único que se entrena

Rango LoRA (r)	**16**
Dropout LoRA	0.05
Learning rate	4e-4
Optimizador	AdamW 8 bits · scheduler lineal
Batch	1 por paso + acumulación de gradientes
Largo máximo	2560 tokens
Datos	split 80 / 10 / 10 · semilla 3407

Diseño experimental: dos rondas, una sola carga del modelo

RONDA A · HIPERPARÁMETROS

	3 épocas	6 épocas
Batch efectivo	8	16
lora_alpha	16	32
Warmup	10 pasos	20 pasos
Weight decay	0.01	0.1
Capas LoRA	atención	atención

RONDA B · CAPAS CON LoRA

3.1 M

Solo atención

q, k, v, o en las 8 capas de atención completa

30.5 M

Todas las capas

+ atención lineal en 24 capas + MLP en las 32

Del mensaje del usuario a la respuesta con acceso a los datos



```
system:
  Eres el asistente de Kalish Manta Analytics. Guías a investigadores ...
  Bases de datos disponibles en el catálogo:
  {catálogo completo por categoría}
  Reglas:
  1. Usa únicamente la información de las fichas del CONTEXTO. No inventes ...
  2. Si el usuario no explicó su investigación, pídele su abstract, hipótesis u objetivo.
  3. Si pregunta qué bases hay, nómbralas e invítalo a la pestaña Catálogo.
  4. Si el mensaje no trata sobre datos para investigación, decláralo con cortesía.
  5. No escribas links: se agregan automáticamente.
  CONTEXTO (fichas de las bases relacionadas con el mensaje):
  [Base de datos: <título>]
  <ficha rápida> [...] <chunk más parecido>
user / assistant: historial (sin links)
user: mensaje actual
```

Prompt Aumentado

07
Demo

El asistente en acción.

Link:

https://laptop-bb3a7uht.tail80d628.ts.net/



Gracias

Kalish Manta Analytics: datos para investigar, a una conversación de distancia.

Link de GitHub

https://github.com/Robertopucp/RAGCentralDatabaseEconomy



Roberto